


ANALISIS SENTIMEN DEEPSEEK



Latar Belakang

Perkembangan teknologi kecerdasan buatan (Artificial Intelligence/AI) semakin pesat dalam beberapa tahun terakhir, munculnya berbagai Large Language Models (LLMs) yang mampu memahami dan menghasilkan teks secara alami. Salah satu model yang mulai menarik perhatian publik adalah DeepSeek, sebuah LLM open-source buatan China yang menawarkan performa kompetitif serta akses terbuka bagi pengembang dan peneliti.


Seiring dengan meningkatnya perhatian terhadap DeepSeek, masyarakat Indonesia mulai mengekspresikan opini mereka melalui media sosial, terutama di Platform X (sebelumnya Twitter), yang dikenal sebagai ruang diskusi terbuka dan dinamis. Dengan tingginya jumlah pengguna aktif di Indonesia, Platform X menjadi sumber data yang kaya untuk menangkap persepsi publik terhadap berbagai isu teknologi, termasuk DeepSeek.

Melalui pendekatan analisis sentimen, penelitian ini berupaya untuk memahami bagaimana masyarakat Indonesia memandang DeepSeek, baik dari sisi kelebihan, kekurangan, maupun potensi penggunaannya di masa depan. Analisis ini diharapkan dapat memberikan wawasan yang lebih dalam terkait penerimaan masyarakat terhadap teknologi AI berbasis bahasa.

Tujuan

1. Mengklasifikasikan sentimen publik terhadap DeepSeek di Platform X (positif, negatif, netral).
2. Mengidentifikasi kata kunci dan topik yang sering muncul dalam percakapan tentang DeepSeek.
3. Menganalisis kecenderungan opini dan persepsi pengguna Platform X terhadap Deepseek.

DATA ACQUISITION METHOD



WEB (X) CRAWLING

EXPLORATORY DATA ANALYSIS

JUMLAH DATA



2157



rows

CONTOH DATA

conversation_id_str	created_at	favorite_count	full_text	...
1883296437968241015	Sat Jan 25 23:30:35 2025	0	setelah nyobain deepseek versi free di webnya ...	...
1883295063608074674	Sat Jan 25 23:25:07 2025	1	Deepseek R1 aku cancel terus claudeAI hahaha	...
1883169534737252446	Sat Jan 25 23:10:17 2025	1	@Yukikaze_D_2 @BudiBukanInte I DeepSeek R1 reason ...	...

EXPLORATORY DATA ANALYSIS

LABELS DISTRIBUTION





POSITIVE WORDCLOUDS




NEGATIVE WORDCLOUDS

MOST COMMON WORDS IN EACH LABEL



METODOLOGI PENELITIAN



Data Cleaning Flow

01.

-	0	+	*	full_text
			1	...
	1			...
	1			...
			1	...
			1	...
		1		...
1				...

02.

-	0	+	*	full_text
	1			...
	1			...
		1		...
1				...

→
remove tagged
irrelevant data
(to_drop)

03.

label	full_text
netral	...
netral	...
positive	...
negative	...

→
create 'label' column
(optional, depends on model)

Data Analysis Pipeline

Text Preprocessing

Lowercase

*Drop
Symbol/URL*

*Stopwords
Removal*

Stemming

Feature Extraction

*TF-IDF
Vectorizer*

*Embedding
(Word2Vec/
BERT)*


Split Data

*Training > 80%
Test > 20%*

Stratified Split

SMOTE

*Handling
Imbalance*



Text Preprocessing

Tautan & Simbol Aneh

(misalnya: https://..., @, #, dll)

Kata Tidak Penting

(termasuk slang seperti: aja, udah, pake)


Kata Berimbuhan

Diubah ke bentuk dasar pakai Sastrawi

(contoh: "bermain" → "main")

Text Preprocessing

label	full_text
...	...
...	...
...	...




@mgppap Wah seru juga ya! DeepSeek dari China kayaknya lagi serius banget dalam menciptakan AGI. Kalo kamu mau tahu lebih tentang AI coba deh mampir sini. <https://t.co/6GrAQwgPWS>



lowercase letters
remove mentions
remove links
remove non-alphabets

label	cleaned
...	...
...	...
...	...



wah seru juga ya deepseek dari china kayaknya lagi serius banget dalam menciptakan agi kalo kamu mau tahu lebih tentang ai coba deh mampir sini



remove stopwords
stemming

seru ya deepseek china kayak serius banget cipta agi kalo ai coba deh mampir

Features Extraction

Komputer tidak memahami teks,
itulah sebabnya kita perlu mengubahnya menjadi representasi numerik.

Metode ekstraksi fitur populer untuk teks:

1. TF-IDF

- Metode paling populer untuk model pembelajaran mesin tradisional.


2. Word2Vec

- Dilatih untuk memahami hubungan semantik antar kata.


3. BERT

- Menghasilkan penyematan kontekstual – perubahan makna kata berdasarkan konteks.


TRAIN-TEST SPLIT



Stratified Split by label



MODELLING




Metrik Evaluasi yang Digunakan

- **Accuracy**
- **Balanced Accuracy**
- **Macro F1**
- **Confusion Matrix**
- **Classification Report**





Perbandingan Model



No	Model	Accuracy	Balanced Accuracy	Macro F1 Score
1	SVM	0.640	0.625456	0.626367
2	Random Forest	0.570	0.533905	0.547123
3	Catboost	0.575	0.530028	0.544039
4	Naive Bayes	0.610	0.605762	0.596944
5	Logistic Regression	0.620	0.597357	0.600075
6	Gradient Boosting	0.575	0.536194	0.547615

Evaluasi Model



Total data test 20% = 200

Contoh

Kesalahan dalam Predict Model

Label Asli	Text (cleaned)	Predict Model
Positif	cobain deh walaupun lemot lebih punya kesadaran cem manusia	Netral
Negatif	heh kok r1 ga akurat ya hmmpss malah lebih akurat yang	Netral
Positif	r1 lagi rame kayanya jadi lemot wkwwk tapi hasilnya emang bagus sih apalagi dikasi web search mana lebih murah inferencenya dibanding dan claude	Netral
Positif	lemot bgt cok sumpah	Negatif

Kesimpulan

Berdasarkan hasil analisis sentimen terhadap model DeepSeek di Platform X, dapat disimpulkan bahwa masyarakat Indonesia menunjukkan beragam opini yang terbagi menjadi sentimen positif, negatif, dan netral. Setelah membandingkan enam model machine learning, Support Vector Machine (SVM) terbukti memberikan performa terbaik dalam klasifikasi sentimen, dengan nilai accuracy dan macro F1 yang unggul di antara model lainnya. Ini menunjukkan bahwa SVM efektif dalam menangani data teks berlabel tidak seimbang serta mampu mengklasifikasikan opini publik secara cukup akurat.

Saran

1. Model SVM yang digunakan masih bisa ditingkatkan melalui hyperparameter tuning atau dengan menerapkan ensemble methods untuk meningkatkan stabilitas prediksi.
2. Ke depannya, analisis sentimen ini dapat diperluas untuk membandingkan DeepSeek dengan LLM lainnya (seperti ChatGPT atau Claude) guna menilai preferensi publik secara lebih luas.
3. Selain labeling manual, dapat dipertimbangkan penggunaan auto-labeling menggunakan model pretrained berbahasa Inggris. Meskipun pendekatan ini dapat mempercepat proses pelabelan, perlu diingat bahwa kualitasnya mungkin tidak sepenuhnya sesuai jika konteks budaya dan bahasa lokal Indonesia tidak diperhitungkan—sehingga kurang cocok untuk fokus penelitian yang menargetkan opini publik Indonesia.

Terimakasih